

AD SOYAD

Rabia Sıla Karaca

ÖĞRENCİ NUMARASI

230212028

DERS ADI

Veri Madenciliği

Yapay Zekâ Mühendisliği

PROJE BAŞLIĞI

SenteTürk: Türkçe Doğal Dil İşleme Modellerinde
Post-Training Quantization (PTQ) Tekniklerinin
Sınıflandırma Başarımı ve Donanım Verimliliği
Üzerindeki Etkilerinin Analizi

İçindekiler

1	Özet	2
2	Veri Seti ve Ön İşleme	2
2.1	Veri İstatistikleri	2
2.2	Ön İşleme Hattı	2
3	Model Mimarisi	3
4	Model Eğitimi	3
4.1	Callbacks ve Eğitim Geçmişi	3
5	INT8 Kuantizasyon	3
6	Sonuçlar ve Grafikler	4
6.1	ROC ve PR Eğrileri	4
6.2	Model Boyutu ve AUC Kayıp Analizi	5
6.3	Tahmin Dağılımı ve Metrik Uyumluluğu	5
6.4	Karışıklık Matrisleri	6
7	Tartışma	6
8	Sonuç	6
	Kaynaklar	7

1 Özet

Bu çalışmada Türkçe metinlere yönelik ikili duygu analizi (pozitif/negatif) gerçekleştiren derin öğrenme tabanlı bir sistem tasarlanmıştır. Toplam **492.782 cümle** üzerinde Zemberek kütüphanesi ile lemmatizasyon, normalleştirme ve paralel ön işleme uygulanmış; Embedding + GlobalAveragePooling mimarisiyle FP32 modeli eğitilmiştir. Model **ROC-AUC = 0.9627**, **PR-AUC = 0.9906** başarısına ulaşmış; post-training INT8 kuantizasyonu ile **74.1 MB → 6.2 MB (12x)** sıkıştırma, yalnızca **%0.04** AUC kaybıyla gerçekleştirilmiştir.

Temel Sonuçlar

FP32 ROC-AUC: 0.9627	INT8 ROC-AUC: 0.9623
FP32 PR-AUC : 0.9906	Sıkıştırma : 12x (74.1 MB → 6.2 MB)
Toplam Veri : 492.782 cümle	AUC Kaybı: %0.04

2 Veri Seti ve Ön İşleme

2.1 Veri İstatistikleri

Tablo 1: Ön İşleme ve Veri Kümeleri

Küme	Ham Satır	Süre
Eğitim	443.817	760.4 s
Test	48.965	92.3 s
Toplam	492.782	852.7 s

Etiketler: *Negative* → 0, *Positive* → 1. İşlem **11 paralel worker** (ProcessPoolExecutor) ile 2.000'lik chunk'lar halinde RAM'e tam yüklenmeden gerçekleştirilmiştir.

2.2 Ön İşleme Hattı

- Temel Temizleme:** Küçük harf, fazla boşluk, URL silme, Türkçe dışı karakter filtreleme.
- Zemberek Normalleştirme:** TurkishSentenceNormalizer ile yazım hatası ve kısaltma standardizasyonu.
- Belirteçleme:** TurkishTokenizer.DEFAULT; tek karakterlik tokenlar elendi.
- Lemmatizasyon:** TurkishMorphology ile morfolojik analiz; her token kök biçimine (lemma) indirildi.

3 Model Mimarisi

Tablo 2: Model Katman Özeti (Toplam 6.467.585 Parametre)

Katman (Tür)	Çıkış Boyutu	Parametre
InputLayer	(None, 128)	0
Embedding (50K $\times$ 128)	(None, 128, 128)	6.400.000
GlobalAveragePooling1D	(None, 128)	0
Dense-ReLU(256) + BN + Dropout(0.4)	(None, 256)	34.048
Dense-ReLU(128) + BN + Dropout(0.4)	(None, 128)	33.408
Dense-Sigmoid(1)	(None, 1)	129
Toplam / Eğitilebilir		6.467.585 / 6.466.817

Derleme: Adam (lr=0.001), Binary Crossentropy, metrik: ROC-AUC.

Vektörleştirme: TextVectorization — max_tokens=50.000, seq_len=128, 300K örnek ile adapt edildi.

4 Model Eğitimi

4.1 Callbacks ve Eğitim Geçmişi

Callbacks: ModelCheckpoint (best_val_roc_auc $\rightarrow$ fp32_best.keras), EarlyStopping (patience=3), ReluSparsityCallback.

Tablo 3: Epoch Bazlı Metrikler (EarlyStopping Epoch 3'te tetiklendi)

Epoch	Train Loss	Train AUC	Val Loss	Val AUC
1	0.0659	0.9931	0.3769	0.9183
2	0.0561	0.9949	0.3930	0.9110
3*	0.0490	0.9958	0.3292	0.9359

Tablo 4: ReLU Aktivasyon Seyrekliği (Epoch Bazlı)

Epoch	dense_relu_256	dense_relu_128
1	%61.8	%61.9
2	%61.0	%58.3
3	%57.2	%59.4

5 INT8 Kuantizasyon

Post-training INT8 kuantizasyonunda FP32 SavedModel, eğitim kümesinden alınan **200 mini-batch temsili veri seti** ile kalibre edilmiş; giriş/çıkış tensörleri float32 olarak korunmuştur.

Tablo 5: Model Boyutu ve Performans Karşılaştırması

Format	Boyut	ROC-AUC	PR-AUC
FP32 (.keras)	74.1 MB	0.9627	0.9906
INT8 (.tflite)	6.2 MB	0.9623	≈ 0.9900
Kazanım	12x küçülme	$-\%0.04$	$-\%0.06$


AUC kaybı formülü:

$$\Delta_{\text{AUC}} = \frac{0.9627 - 0.9623}{0.9627} \times 100 \approx \%0.04$$

6 Sonuçlar ve Grafikler


6.1 ROC ve PR Eğrileri

1. Sınıflandırma Gücü (ROC & PR)




Şekil 1: G1 – ROC ve PR Eğrileri: FP32 (AUC=0.9627) ve INT8 (AUC=0.9623) karşılaştırması. Her iki model neredeyse özdeş eğri çizmektedir.

6.2 Model Boyutu ve AUC Kayıp Analizi




Şekil 2: Model Boyutu ve Başarı Korunma Oranı

6.3 Tahmin Dağılımı ve Metrik Uyumluluğu



Şekil 3: Tahmin Dağılımı ve 5 Metrik Radar Karşılaştırması

6.4 Karışıklık Matrisleri



Şekil 4: FP32 ve INT8 Normalize Karışıklık Matrisleri (Gerçek sınıfa göre %)

7 Tartışma

Güçlü Yönler:

- FP32 ROC-AUC = 0.9627 — Türkçe ikili duygu analizinde yüksek başarı.
- INT8 kuantizasyonu %0.04 kayıpla **12x boyut azaltması** sağladı.
- Zemberek lemmatizasyonu, Türkçe'nin agglutinative yapısını etkin ele aldı.
- 11 paralel worker ile 490K satır veri 14 dakikada işlendi.

Sınırlılıklar:

- GlobalAveragePooling1D sıra bilgisini göz ardı eder (olumsuzlama zayıflığı).

Gelecek Çalışmalar: BERTürk / LSTM tabanlı mimari karşılaştırması, veri artırma, yapısal budama (pruning), mobil/kenar cihaz dağıtımı.

8 Sonuç

Bu çalışma; Türkçe duygu analizinde derin öğrenme + INT8 kuantizasyonunun üretim ortamları için verimli ve yüksek başarılı bir çözüm sunduğunu kanıtlamıştır. 492.782 cümlelik büyük ölçekli veri ile elde edilen **FP32 ROC-AUC = 0.9627**, INT8 ile **12x boyut azaltımı** ve yalnızca **%0.04 performans kaybı**, modelin kenar cihaz dağıtımına hazır olduğunu göstermektedir.

Proje Özet Bulguları

- **492.782 cümle** – Büyük ölçekli Türkçe veri seti başarıyla işlendi.
- **ROC-AUC = 0.9627 (FP32) → 0.9623 (INT8).**
- **12x sıkıştırma:** 74.1 MB → 6.2 MB, kayıp %0.04.
- INT8 TFLite modeli üretim ve kenar cihaz dağıtımına hazırdır.

Kaynaklar

1. Han, S., et al. (2015). *Deep Compression: Compressing Deep Neural Networks*. *arXiv*.
2. Gholami, A., et al. (2021). *A Survey of Quantization Methods*. *arXiv*.
3. Abadi et al. (2016). *TensorFlow: A system for large-scale ML*. USENIX OSDI.
4. Akın & Akın (2007). *Zemberek, an open source NLP framework for Turkic languages*.
5. Jacob et al. (2018). *Quantization and Training of NNs for Integer-Arithmetic Inference*. CVPR.
6. Kingma & Ba (2015). *Adam: A Method for Stochastic Optimization*. ICLR.
7. Ioffe & Szegedy (2015). *Batch Normalization*. ICML.
8. TensorFlow (2024). *Post-training quantization*. https://www.tensorflow.org/lite/performance/post_training_quantization